AI4I 2020 — Makine Arızası Tahmini: Sınav Raporu

İsim-Soyisim	Öğrenci No	Bölüm	Ders	Dönem
Tuğba Tuana Kaygısız	**2511317024**	MAKÜ-FEF Veri Bilimi ve Analitiği (VBA)	Makine Öğrenmesi — Arasınav (Bilgisayar Bölümü, Soru 1–3)	2026-2027 Güz

Veri: UCI AI4I 2020 Predictive Maintenance (10.000 kayıt, 14 sütun), hedef `Machine failure`. Bütün sayılar ve grafikler `kod/sinav_cozumu.ipynb` defterinden gelir (`random_state=42`, yeniden çalıştırınca aynı sonuç). Veride eksik hücre ve tekrar eden satır yok. Keşif analizi yalnız eğitim kümesinde yapıldı; test kümesi yalnız son ölçümde kullanıldı.

SORU 1 — Veriyi tanıma ve problemi anlama

a) Machine failure dağılımı ve sınıflandırma zorluğu

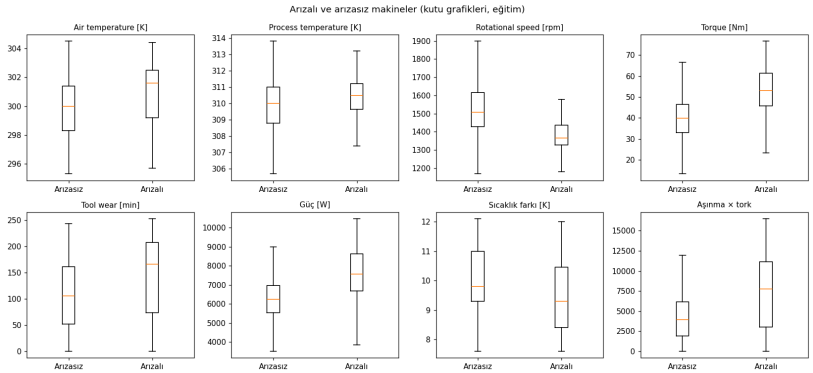
10.000 kaydın **9.661'i arızasız (%96,6), 339'u arızalı (%3,4)**. Zorluklar:

- **Ciddi sınıf dengesizliği:** "Hiçbir makine arızalanmaz" diyen boş bir tahmin bile %96,6 accuracy alır ama tek arıza yakalayamaz. Accuracy yanıltıcıdır; **recall, precision ve F1** birlikte kullanılmalıdır.
- **Az arıza örneği:** Model yalnız 271 arıza (eğitim) görerek öğrenir. Bölme **stratified** olmalı, sonuçlar **K-Fold** ile doğrulanmalıdır.
- **Tek etiket altında birden çok neden:** ısı (HDF), güç (PWF), zorlanma (OSF), takım aşınması (TWF) ve rastgele (RNF) arızalar aynı etikette. Rastgele arızalar hiçbir sensörle öngörülemez; %100 başarı mümkün değildir.

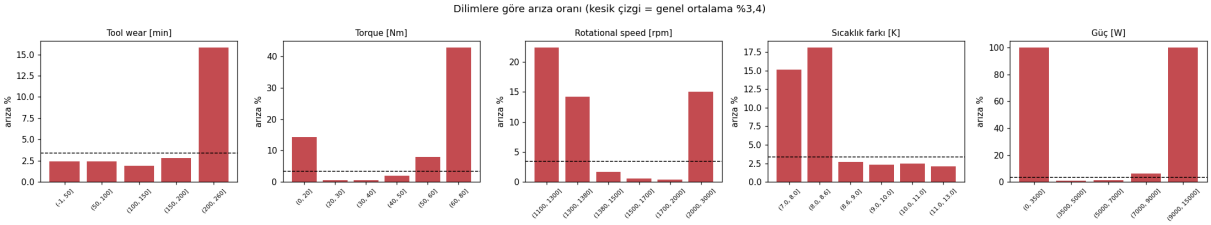
b) Arızalı ve arızasız makinelerin karşılaştırılması (eğitim kümesi)

Değişken	Arızasız ort.	Arızalı ort.	Arızalı medyan	Fark	Tek başına AUC*
Tork [Nm]	39,7	50,2	53,2	**+%26,5**	**0,77**
Dönüş hızı [rpm]	1.541	1.501	1.366	−%2,6 (medyanda −%9)	**0,76**
Takım aşınması [dk]	106,5	141,4	166	**+%32,8**	0,65
Hava sıcaklığı [K]	300,0	300,9	301,6	+%0,3	0,64
İşlem sıcaklığı [K]	310,0	310,3	310,5	+%0,1	0,57
Güç [W] = tork × devir (hesaplanan)	6.247	7.291	7.559	+%16,7	0,74
Sıcaklık farkı [K] = işlem − hava (hesaplanan)	10,0	9,4	9,3	−%6,1	0,66

* Yalnız o değişkenle arızalıyı arızasızdan ayırma gücü (0,5 = ayıramaz, 1 = kusursuz).



Ortalamalar tek başına yetmediği için arızanın **hangi aralıkta** sıklaştığına bakıldı (genel ortalama %3,4):



Arıza oranı: takım aşınması > 200 dk → **%15,8** (altında %2–3) · tork > 60 Nm → **%42,8**, tork < 20 Nm → %14,3 (20–40 Nm arasında %0,6) · devir < 1.300 rpm → **%22,4**, > 2.000 rpm → %15 · sıcaklık farkı < 8,6 K → **%15–18** · güç < 3.500 W ya da > 9.000 W → **%100** (82 kaydın tamamı) · tork 60–80 Nm ve devir 1.380–1.500 rpm birlikte → **%61,9** · ürün kalitesi L / M / H → %4,1 / %2,4 / %2,0.

Üretim yönetimi için çıkarımlar: (1) Takımlar 200 dakikaya gelmeden değiştirilmeli; sonrasında arıza yaklaşık 6 kat artıyor. (2) Makine 3.500–9.000 W güç aralığında tutulmalı; **yüksek tork + düşük devir** en tehlikeli çalışma noktası. (3) İşlem ile ortam sıcaklığı farkı 8,6 K'nin altına düşerse soğutma artırılmalı ya da devir yükseltilmeli. (4) Düşük kaliteli (L tipi) ürün hatlarında arıza iki kat sık; bakım daha sık planlanmalı.

c) Arıza tahmini için daha yararlı değişkenler

Tork ve **dönüş hızı** en güçlü iki değişken (AUC 0,77 ve 0,76): arızaların çoğu aşırı yükte ya da düşük devirde oluyor, kutu grafiklerinde iki grup açıkça ayrışıyor. **Takım aşınması** ortalamada orta düzeyde (0,65) ama 200 dk eşiğinden sonra çok belirleyici. **Hava ve işlem sıcaklığı tek başına zayıf**; asıl bilgi ikisinin **farkında** (fark küçükse makine ısıyı atamıyor). En yararlı bilgi değişkenlerin **birleşimlerinde**: güç (tork × devir), aşınma × tork ve sıcaklık farkı arızanın fiziksel nedenini doğrudan ölçüyor (etkisi

Soru 3b'de gösterildi). Type zayıf bir yardımcı değişken. UDI ve Product ID kimliktir; TWF/HDF/PWF/OSF/RNF ise arızanın sonucudur (sızıntı) — hiçbiri modele verilmedi.

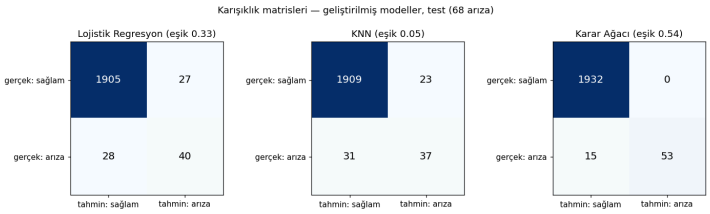
SORU 2 — Arıza tahmin modelleri

a) Eğitim / test bölmesi ve ön işleme

Tercih	Ne yapıldı	Neden
Bölme	**%80 / %20, stratified**, `random_state=42` → eğitim 8.000 (271 arıza), test 2.000 (68 arıza)	Arıza çok az; stratify olmasa test kümesine şans eseri çok az arıza düşebilirdi
Çıkarılanlar	UDI, Product ID, TWF, HDF, PWF, OSF, RNF	Kimlikler bilgi taşımaz; arıza türleri sonucun kendisidir (sızıntı)
Girdiler	Type (L<M<H sırasıyla 0/1/2), hava ve işlem sıcaklığı, devir, tork, takım aşınması	Tahmin anında bilinen değerler; Type'ın doğal sırası var
Ölçekleme	LR ve KNN'de StandardScaler; ağaçta yok	KNN uzaklıkla çalışır, ölçeksiz devir (~1.500) torku (~40) bastırırdı; ağaç ölçekten etkilenmez
Sızıntı önlemi	Ölçekleme ve kodlama Pipeline içinde	Her çapraz doğrulama katında yalnız eğitim kısmından öğrenilir
Aykırı değer	Silinmedi	Aykırı torklu 56 kaydın %89'u arıza: aykırı değer arıza sinyalinin kendisi
Yeni özellikler (geliştirilmiş sürüm)	Güç = tork × devir × 2π/60 · sıcaklık farkı · aşınma × tork · zorlanma oranı = (aşınma × tork) / tip sınırı (L 11.000, M 12.000, H 13.000; veri belgesinden). LR'ye ayrıca kareler ve ikili çarpımlar; KNN'e yalnız fizik özellikleri + devir + aşınma	Soru 1c: arıza ham sütunlardan çok birleşimlerine bağlı. LR düz çizgi çizer, kareli terimlerle "çok düşük ya da çok yüksek güç" penceresini görür; KNN'de dönem bilgisi taşıyan ham sıcaklıklar komşuluğu bozar
Ayar ve eşik seçimi	Eğitimde **5 katlı Stratified K-Fold + GridSearch** (ölçüt F1); karar eşiği eğitimdeki CV tahminlerinde F1'i en yüksek yapan değer	Test kümesi ayar ve eşik seçiminde hiç kullanılmadı. Geliştirilmiş: LR C=100, eşik 0,33 · KNN k=1 · ağaç derinlik 5 (entropy)

b) Test kümesinde üç modelin karşılaştırması (2.000 kayıt, 68 arıza, eşik 0,5)

Model	Girdi	Accuracy	Precision	Recall	F1	Kaçan arıza (FN)	Yanlış alarm (FP)	5×5 tekrarlı CV F1
Lojistik Regresyon	ham	0,968	0,615	0,118	0,198	60	5	0,315 ± 0,065
Lojistik Regresyon	**geliştirilmiş** (eşik 0,33)	0,973	0,597	**0,588**	**0,593**	28	27	0,634 ± 0,056
KNN	ham	0,972	0,628	0,397	0,487	41	16	0,510 ± 0,061
KNN	**geliştirilmiş**	0,973	0,617	**0,544**	**0,578**	31	23	0,594 ± 0,047
Karar Ağacı	ham	0,985	0,806	0,735	0,769	18	12	0,685 ± 0,048
Karar Ağacı	**geliştirilmiş**	**0,993**	**1,000**	**0,779**	**0,876**	**15**	**0**	**0,891 ± 0,031**
Kıyas: herkese "arızasız" de	—	0,966	0	0	0	68	0	—



Fizik özellikleri üç modeli de iyileştirdi: F1 LR'de **0,20 → 0,59** (yakalanan arıza 8 → 40), KNN'de 0,49 → 0,58, ağaçta 0,77 → 0,88 (yanlış alarm 12 → 0). Sıralama testte ve 25 ölçümlük tekrarlı çapraz doğrulamada aynı: **Karar Ağacı > LR > KNN**. Kazanç dayanıklı: zaman sıralı bölmede F1 0,63 / 0,60 / 0,84; veri belgesindeki sınırlar (zorlanma oranı) çıkarılınca bile ağaç 0,867 test F1'de kalıyor. KNN'de seçilen k=1 ezbere açık; bu yüzden üretim için uygun değil.

c) En yüksek accuracy = fabrika için en iyi model mi?

Hayır, **accuracy'ye göre seçim yapılamaz.** Bu veride en yüksek accuracy'li model (ağaç, 0,993) recall ve F1'de de birinci, ama bu accuracy'nin doğru ölçüt olduğunu göstermez: modellerin accuracy'si neredeyse aynı (0,968–0,993) iken recall 0,12 ile 0,78 arasında değişiyor. Geliştirilmiş LR ve KNN'in accuracy'si aynı (0,973) ama biri 28, öbürü 31 arıza kaçırıyor. Lojistik Regresyon'un %96,8'i, hiçbir şey yapmayan boş tahminin %96,6'sıyla aynı düzeyde; ama 68 arızanın yalnız 8'ini buluyor. Fabrika için önemli olan doğru tahmin yüzdesi değil, **kaçan arıza sayısı (recall)**, **yanlış alarm yükü (precision)** ve bunların maliyetidir. En iyi model bile 15 arıza kaçırıyor; eşiğin fabrikanın maliyetine göre ayrıca ayarlanması gerekir.

d) Seçilen model: geliştirilmiş Karar Ağacı (operasyonel gerekçelerle)

- **Maliyet:** Yanlış alarm 1 birim, kaçan arıza c birim sayıldı; her modelin eşiği eğitimdeki çapraz doğrulama tahminleriyle seçilip testte ölçüldü (geliştirilmiş modeller). c ≤ 10 iken en düşük toplam maliyet açık ara ağaçta; c = 20'de LR yakın (271'e 322), ama 111 yanlış alarm pahasına:

Kaçan arıza maliyeti (c)	Lojistik Regresyon	KNN	Karar Ağacı	Ağacın eşiği → kaçan arıza / yanlış alarm
1	50	54	**15**	0,54 → 15 / 0
5	152	178	**58**	0,29 → 11 / 3
10	233	333	**113**	0,29 → 11 / 3
20	**271**	643	322	0,01 → 3 / 262

- **Açıklanabilirlik:** Ağaç yalnız 9 yapraklı (derinlik 5); kuralları bakım ekibi doğrudan okuyabilir: "zorlanma oranı > 1 → arıza", "güç > 9.004 W ya da < 3.496 W → arıza", "sıcaklık farkı ≤ 8,7 K ve devir ≤ 1.380 → ısı arızası riski". Bunlar Soru 1'deki bulguların aynısı. KNN'nin kararı "en benzer kayıt böyleydi" demektir; açıklanamaz.
- **Hız ve bakım:** 2.000 kaydı ağaç ~2 ms'de, LR ~4 ms'de, KNN ~11 ms'de tahmin ediyor. KNN bütün eğitim verisini saklayıp her tahminde taramak zorunda; ağaç kısa bir kural listesidir, hat kontrol sistemine gömülebilir.
- **Kararlılık ve zaman:** Tekrarlı ölçümde F1 0,891 ± 0,031. Zaman sıralı bölmede de (ilk 8.000 kayıtla eğit, son 2.000'i tahmin et) F1 0,84 ve sıfır yanlış alarm. Ham sütunlu ağaç bu testte 0,47'ye düşüyordu, çünkü hava sıcaklığından "hangi dönemdeyiz" bilgisini ezberliyordu; yeni ağaç hava sıcaklığını hiç kullanmıyor (önem 0).

SORU 3 — Modeli gerçek hayatta kullanmak

a) Daha kritik hata

Kaçan arıza (yanlış negatif) daha kritiktir. Arızalanacak makineye "sağlam" demek planlanmamış duruş demektir: hat bekler, yarım kalan ürün hurdaya çıkar, teslimat gecikir, iş güvenliği riski doğar. Yanlış alarm ise planlı yapılabilen kısa bir kontrol ve gereksiz bakım maliyetidir; üretimi durdurmaz. Öncelik **recall**; ancak yanlış alarm sınırsız artarsa bakım bütçesi şişer ve ekip alarmlara güvenmez, bu yüzden precision da izlenmelidir. 2d'deki maliyet hesabında kaçan arızanın en az 5 kat pahalı olduğu her durumda en iyi eşik 0,5'in altında çıkıyor.

b) Arıza yakalamayı artıracak değişiklikler ve olumsuz sonuçları

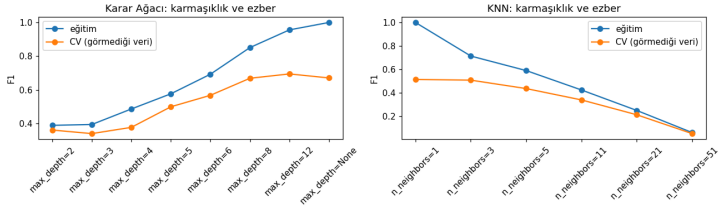
Değişiklik	Bu veride ölçülen etki (karar ağacı, test)	Olumsuz sonucu
Karar eşiğini düşürmek (0,5 → 0,2)	Kaçan arıza 18 → 15	Yanlış alarm 12 → 35 (yaklaşık 3 kat): gereksiz bakım, alarm yorgunluğu
Fiziğe dayalı yeni özellikler (Soru 2'de uygulandı)	Ağaç: kaçan arıza 18 → 15, yanlış alarm 12 → **0**; LR: yakalanan arıza 8 → **40**; zaman sıralı testte ağaç F1 0,47 → **0,84**	Zorlanma sınırları bu sentetik verinin belgesinden; gerçek fabrikada üretici verileriyle yeniden belirlenmeli. LR'nin kareli terimleri ezber riskini artırır
Sınıf ağırlığı / azınlık sınıfı çoğaltma	Arızalara daha çok ağırlık → recall artar	Yanlış alarm hızla artar; yapay örnekler gerçekte olmayan arızalar üretebilir
Daha çok veri, yeni sensörler (titreşim, akım), daha güçlü modeller	Öngörülemeyen arızaların bir kısmı görünür hâle gelir	Maliyet ve kurulum süresi; açıklanabilirlik azalır

Yeni özelliklerle ağaç artık hava sıcaklığına değil zorlanma oranına, güce, devire ve sıcaklık farkına bakıyor; yani dönemi ezberlemek yerine arızanın gerçek nedenini öğreniyor. Yine de %100 yakalama beklenmemeli: rastgele arızalar sensörlerle öngörülemez (zaman sıralı testte en iyi model 39 arızanın 11'ini kaçırıyor).

c) Eğitimde çok yüksek, testte düşük başarı

Bu **aşırı öğrenmedir (overfitting):** model genel kuralı değil, eğitim verisindeki rastlantısal ayrıntıları ezberlemiştir. Bu veride ölçüldü (F1; CV = modelin görmediği kısım):

Model / ayar	Eğitim	CV	Fark		Model / ayar	Eğitim	CV	Fark
Ağaç, sınırsız derinlik	1,000	0,671	0,329		KNN, k = 1	1,000	0,513	0,487
Ağaç, seçilen (derinlik 10, yaprakta ≥ 10)	0,785	0,727	**0,058**		KNN, k = 5	0,589	0,435	0,154



Öneri 1 — Modeli sadeleştirmek: ağaçta maksimum derinliği sınırlamak ve yaprakta en az kayıt şartı koymak (budama), KNN'de daha büyük k, Lojistik Regresyon'da daha güçlü düzenlileştirme. Bu veride yaprak şartı eğitim–CV farkını 0,33'ten 0,06'ya indirdi. **Öneri 2 — Ayarları K-Fold çapraz doğrulamayla seçmek ve test kümesini korumak:** derinlik, k gibi ayarlar eğitim başarısına göre değil doğrulama skoruna göre seçilmeli; test kümesi yalnız en sonda bir kez kullanılmalı (veri zaman sıralı olduğu için doğrulama da sırayı korumalı). Ek olarak daha çok arıza verisi toplamak ve dönemi ezberleten girdiler yerine fiziksel anlamı olan özellikler kullanmak ezberi azaltır.